



INTELIGENCIA ARTIFICIAL

APRENDIZAJE SUPERVISADO

APRENDIZAJE SUPERVISADO

En términos generales, en el aprendizaje supervisado, el objetivo consiste en aprehender una función que sea capaz de predecir de manera precisa, ciertos valores vinculados a la entrada. La función adquirida puede ser utilizada para pronosticar nuevos valores relacionados con entradas inéditas que provengan del dominio. Este dominio puede ser un conjunto de valores, aunque en numerosas ocasiones se manifestará como una función continua. En tales circunstancias, los algoritmos de aprendizaje suelen ser entrenados con una gran cantidad de datos. La manera en que estos algoritmos logran hacer predicciones más eficientes a partir de los datos obtenidos, se conoce, comúnmente, como el modelo del aprendiz.

El aprendizaje supervisado comienza con un conjunto de datos conocidos; para cada entrada del conjunto de datos, se especifica la salida asociada. El objetivo en este caso, consiste en averiguar la mejor correspondencia posible entre nuestros datos y las salidas; esta correspondencia se establece mediante la determinación de un modelo. Naturalmente, el procedimiento de selección de modelo juega un papel muy importante; conseguir un modelo exageradamente complejo que ofrezca un ajuste excesivo, provocará que el modelo se centre en características no deseadas del conjunto de datos y puede generalizar mal (en otras palabras, hacer predicciones erróneas, para datos a los que no fue entrenado).

Como se muestra en la siguiente figura, a partir de conocer X (entrada) y Y (salida) se trata de identificar el comportamiento del proceso (se crea un modelo a partir de estos datos); estos se conocen como modelos de caja negra, donde no se tiene información relevante del proceso.

Figura 1. Relación entrada y salida en búsqueda del proceso




Por su manera de ser tratado, el aprendizaje supervisado podemos tener dos variantes: **regresión** para cuando el valor a predecir es cuantitativo (numérico) y **clasificación** cuando el valor a predecir es cualitativo (cualidades – características – discreto).

Problemas de regresión


Para los procesos de **regresión**, se utilizan los datos de entrada y salida, para tratar de modelar el proceso sin conocerlo a profundidad, donde se busca encontrar una función $f(x)$ que, a partir de los datos de entrada X , realice una predicción del valor de la salida Y .

Figura 2. Proceso del algoritmo para encontrar la función



En la siguiente figura, se muestra cómo los puntos rojos son los datos originales y, a partir de esto, se genera una función de aproximación, la recta azul que busca replicar el comportamiento y tendencias de los datos de la mejor manera; en este caso, es una regresión lineal porque es una recta, pero se pueden generar regresiones de mayor orden, según sea necesario.

Figura 3. Gráfica de ejemplo de una regresión lineal



Algunas de las aplicaciones del ML a partir de regresiones, se muestran a continuación.

Figura 4. Aplicación de los algoritmos de regresión

REGRESIONES	Predicción de precios de vivienda.
	Predicción de variables ambientales (temperatura, humedad, etc.).
	Predicción de ventas.
	Predicción de consumo de servicios públicos.
	Predicción de tiempos de entrega.

En síntesis, se observa que en todas las aplicaciones mostradas anteriormente, el objetivo final es predecir una variable de tipo numérica y que es continua; para cada una de ellas se pueden aplicar diferentes tipos de algoritmos, asociados a sus características.

Problemas de clasificación

En el caso de los problemas de clasificación, el ML busca a partir de los datos de entrada y salida, crear un modelo que permita etiquetar o clasificar el resultado de la salida, a partir de nuevos datos de entrada; los problemas de clasificación se dividen en dos grandes grupos, que se muestran en la siguiente figura.

Figura 5. Tipos de problemas de clasificación



Para el caso de la clasificación, se suele utilizar la matriz de confusión para entender la confiabilidad de los resultados; la matriz relaciona la etiqueta predicha por el modelo y la etiqueta real; en la siguiente figura, se muestra un ejemplo en el que la etiqueta 0 que representa una clase, en total son 68, donde el sistema predijo correctamente 63 y se equivocó en 5 casos, y para la segunda clase 1, se tienen un total de 32, donde acertó en 28 casos y el sistema se equivocó en 4.

Figura 6. Matriz de confusión

