

INTELIGENCIA ARTIFICIAL

APRENDIZAJE NO SUPERVISADO

APRENDIZAJE NO SUPERVISADO

El aprendizaje no supervisado, se presenta cuando la tarea implica predecir alguna propiedad relacionada con los datos de entrada, sin que el aprendizaje esté guiado por los datos de salida, que se consideran su conocimiento. En términos más simples, la máquina no recibe entrenamiento; en cambio, la máquina misma selecciona los conjuntos estadísticamente más significativos, de los cuales extraerá sus propias conclusiones.

En la práctica, en el aprendizaje supervisado, el objetivo es evaluar indirectamente a la máquina, mientras que, en el aprendizaje no supervisado, la evaluación se realiza de manera directa. Por esta razón, los resultados en el aprendizaje supervisado, suelen ser generalmente superiores a los del aprendizaje no supervisado. En el aprendizaje por refuerzo, se considera que el agente modificará su comportamiento, a lo largo de una secuencia de tiempo.

En este segundo gran enfoque sobre el aprendizaje automático, el aprendizaje no supervisado, las computadoras se enfrentan a la enorme tarea de explorar datos que carecen de etiquetas como guía. A pesar de la ausencia de ejemplos etiquetados de dinámicas de interés, se puede buscar alguna estructura subyacente en ellos. Entendiendo por "descubrir estructura", cualquier exploración de los datos orientada a identificar relaciones relevantes para la tarea de interés (en casos sencillos, descubrimiento de *clusters*, pero también dependencias no lineales, reducciones efectivas de dimensionalidad, patrones frecuentes, etc.).

Al menos matemáticamente, siempre hay estructura cuando se generan observaciones a partir de un modelo estocástico. Por ejemplo, en el caso de la generación de datos a partir de una distribución gaussiana, sencilla y medible, con pocas muestras, inspeccionar mutuamente cómo han variado las distintas dimensiones, resulta valioso.

Con respecto al análisis de problemas no supervisados, los modelos que subyacen a la generación de los datos, son más ricos. Es por esa misma razón que la tarea resulta intrínsecamente más compleja, pero las posibilidades de encontrar una estructura previa de interés, resultan tentadoras. La forma clásica de explorar subyacentia estructural en los datos, se basa en transformar la dimensionalidad con el fin de representar "mejor" las observaciones. Para eso existe un teorema clásico que garantiza que los datos inmersos en un espacio métrico **n-dimensional**, si están distribuidos de una forma en R_k , siempre podrán ser representados mucho mejor en R_{k+1} si se permiten las proyecciones suavemente diferentes, entre los dos espacios.

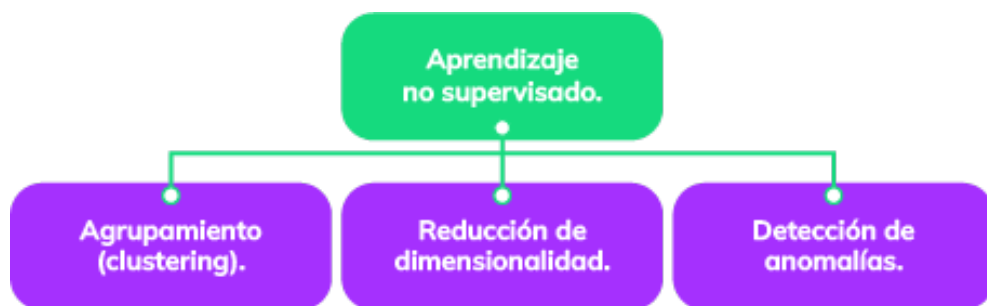
El algoritmo se alimenta por sí solo con los datos de entrada, las muestras utilizadas para aprender no están etiquetadas: el algoritmo no dispone de información acerca de las clases. El objetivo consiste en construir un modelo que sea capaz de descubrir estructuras en los datos de entrada; se dice que es una técnica de aprendizaje computacional, que intenta encontrar patrones ocultos en las métricas de entrada.

El problema principal en la técnica de aprendizaje no supervisado, radica en la dificultad de contrastar las hipótesis relacionadas con las estructuras ocultas. No obstante, su uso es muy apreciable en diversos ámbitos, dado que las situaciones no supervisadas son tan abundantes como las situaciones supervisadas en la naturaleza.

Por ejemplo, un banco que tiene un conjunto de datos de sus clientes disponibles, podría intentar segmentar esos clientes en diferentes grupos y así identificar características similares entre ellos. Finalmente, el modelo descriptivo del banco de los clientes, podría ayudar al departamento de gestión de riesgos.

Los problemas de aprendizaje no supervisado se dividen principalmente en agrupamiento, reducción de dimensionalidad y a partir de los anteriores, la detección de anomalías; cuando se habla de agrupamiento, se busca identificar grupos de datos que comparten ciertas características o tendencias específicas; en la reducción de dimensionalidad, es una técnica utilizada para disminuir la cantidad de variables (dimensiones) en un conjunto de datos, mientras se preserva la mayor cantidad posible de información relevante, es decir, se eliminan las variables que no son tan relevantes, para realizar un modelo.

Figura 1. Aplicaciones del aprendizaje no supervisado



En la siguiente figura se muestra un ejemplo de *clustering* de clientes, donde se identifican baricentros (centros de concentraciones de datos), donde cada uno se asocia a sus tendencias de compra; se puede observar cómo el centro asociado al clúster "descuidados" está mucho más concentrado que los otros; en cambio el clúster "objetivo", está mucho más disperso por lo que tienen características diferenciales entre las mismas personas que hacen parte del clúster.

Figura 2. Ejemplo gráfico de agrupamiento

